

# Desarrollo de un método de entrenamiento para el control de una prótesis mioeléctrica transradial para personas con amputación del miembro superior derecho integrando métodos de Machine Learning

Cano Rodríguez, Diego Gael

2024

---

<https://hdl.handle.net/20.500.11777/6128>

<http://repositorio.iberopuebla.mx/licencia.pdf>

# Desarrollo de un método de entrenamiento para el control de una prótesis mioeléctrica transradial para personas con amputación del miembro superior derecho integrando métodos de Machine Learning

Cano Rodríguez Diego Gael ( séptimo semestre en Ingeniería Biomédica)<sup>1</sup>, Eugenio Reyes Carlos Sebastián ( séptimo semestre en Ingeniería Biomédica)<sup>1</sup>, García Sánchez Alexia ( séptimo semestre en Ingeniería Biomédica)<sup>1</sup>, Merino Arroyo Carlos Miguel (profesor responsable)<sup>1</sup>, Moreno Hernández Ana (profesor asesor) <sup>1</sup>y Acevedo Escalante Francisco Manuel (profesor asesor)<sup>1</sup>.

<sup>1</sup>Universidad Iberoamericana Puebla, San Andrés Cholula, Puebla, México

**Palabras clave:** Aprendizaje supervisado, Machine Learning, Mioeléctrico, Procesamiento de señales, Prótesis.

\***Autor Corresponsal:** alexia.garcia.sanchez@iberopuebla.mx

## Introducción

En México, aproximadamente 780 mil personas viven con alguna forma de amputación y más de 5 millones tienen una discapacidad motriz (INEGI). La Academia Nacional de Cirugía reporta unas 75 amputaciones diarias, señalando un aumento en su incidencia y la necesidad urgente de atención. Sin embargo, el sistema de salud enfrenta retos importantes: el Instituto Mexicano del Seguro Social (IMSS) solo cubre amputaciones laborales y el Sistema Nacional para el Desarrollo Integral de la Familia (DIF Nacional) tiene una capacidad limitada para fabricar prótesis por restricciones presupuestarias. Instituciones como el Instituto Nacional de Rehabilitación (INR), el Hospital Militar y el Centro de Rehabilitación e Inclusión Infantil Teletón (CRIT) ayudan, pero no logran cubrir la demanda [1]. Esto impacta la salud y economía, debido al alto costo del equipo médico y tratamientos, que varía según el tipo de amputación y rehabilitación [2], [3].

Otro desafío es la falta de personal capacitado, lo que obliga a los especialistas a desplazarse para entrenar a los usuarios en el uso de prótesis, aumentando los costos [1].

Este proyecto busca desarrollar un método de entrenamiento para controlar una prótesis transradial mediante machine learning, interpretando y adaptando las señales electromiográficas (EMG) del usuario para generar respuestas inmediatas. A diferencia de los sistemas de control directo actuales, que limitan el control a una sola articulación, el machine learning permite una precisión y adaptabilidad superiores al manejar datos etiquetados [4-7].

## Metodología

Se diseñó un prototipo funcional de prótesis que integra un circuito de control, con un módulo de adquisición y procesamiento de señales EMG y una Raspberry Pi. El sistema utiliza electrodos superficiales para captar señales de contracción muscular estos electrodos se conectan al módulo sensor muscular que se encarga de amplificar y filtrar las señales, el módulo integra un amplificador de instrumentación AD8221 con una ganancia variable, los filtros que utiliza son filtros pasa altas con una frecuencia de corte de 15 Hz [8]. Estas señales se convierten de analógicas a digitales mediante un convertidor ADC integrado en un Arduino UNO, que enviar las señales a la Raspberry Pi, donde un modelo de machine learning interpreta los patrones de actividad muscular para activar los actuadores de la prótesis, logrando movimientos específicos [9], [10].

Para entrenar el modelo, se generó una base de datos con 250 señales EMG. Previo a la toma de la señal se limpió el antebrazo derecho del usuario para asegurar buen contacto entre electrodos y piel, ubicando dos en el músculo flexor superficial de los dedos del brazo derecho y un tercer electrodo en el codo derecho [11], [12]. Cada participante realizó 5 movimientos manuales para registrar los datos [13].

El conjunto de datos se dividió para utilizar el 70% del total para el entrenamiento del modelo, 20% para la validación y 10% para el test.

Se empleó un modelo LSTM (Long Short-Term Memory) que es una variante de una RNN (Recurrent Neural Network) por su capacidad de manejar datos secuenciales, ideal para el análisis de señales EMG [14-16]. Para evaluar el modelo se obtienen las métricas se loss y accuracy, que representa el porcentaje total de valores correctamente clasificados tanto positivos como negativos (Ec. 1), de las etapas de entrenamiento y validación, además se utiliza matriz de confusión para calcular métricas de clasificación mediante datos etiquetados en la etapa de test y se obtienen las curvas ROC para cada una de las clases [17-20].

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Donde:

TP = True Positive

TN= True Negative  
 FP = False Positive  
 FN = False Negative

## **Resultados**

El desarrollo y prueba del prototipo de prótesis mioeléctrica controlada por machine learning obtuvo los siguientes resultados: se imprimió el modelo 3D de la prótesis mioeléctrica utilizando material PLA (Fig. 1) en la cual se integró el circuito electrónico que incluye las etapas de adquisición de la señal, filtrado y amplificación, la etapa de conversión de la señal analógica a digital, el procesador del modelo de clasificación y por último el microcontrolador que activa los motores (Fig. 2).

Para generar el dataset se registraron 50 señales por cada movimiento: movimiento 0 (reposo), movimiento 1 (pinza de llave), movimiento 2 (agarre de gancho), movimiento 3 (agarre de poder), y movimiento 4 (agarre de alcance), (Fig. 3), este conjunto de señales se dividió en un 70% para el entrenamiento del modelo de clasificación de machine learning, 20% para la validación y 10% para la prueba. Al entrenar el modelo obtuvimos un accuracy máximo de 0.81 en el entrenamiento y un accuracy máximo de 0.72 en la validación (Fig. 4), una pérdida mínima de 0.6 en el entrenamiento y una pérdida mínima de 0.9 durante la validación (Fig. 5) y al realizar el test el modelo clasificó las señales del movimiento 0, movimiento 1 y movimiento 4 de manera correcta, en el caso del movimiento 2 solo clasificó de manera correcta el 33% de las señales y del movimiento 3 el 66.7% de señales de esa clase fueron clasificadas de manera correcta (Fig. 6).

Al introducir una señal en el circuito de control de la prótesis se configuro cada uno de los movimientos usando anteriormente mencionados, dependiendo del resultado del modelo de clasificación se generará cada uno de los movimientos.

## **Análisis de resultados**

El desarrollo y prueba del prototipo de prótesis mioeléctrica controlada mediante machine learning han arrojado resultados alentadores en cuanto a su diseño y precisión en la clasificación de movimientos. Durante la fase de construcción, se imprimió en 3D el modelo de prótesis utilizando PLA, un material que proporciona resistencia y es adecuado para la creación de prototipos funcionales. En este modelo se integró un circuito electrónico que incluye las etapas necesarias para procesar las señales mioeléctricas: adquisición, filtrado, amplificación, conversión de señal de analógica a digital y procesamiento de las señales mediante un microcontrolador que activa los motores de la prótesis. Esta configuración permite el flujo completo de procesamiento de señales musculares para convertirlas en movimientos específicos de la prótesis.

Para entrenar el modelo de machine learning, se generó un dataset que consistió en 50 señales para cada tipo de movimiento (reposo, pinza de llave, agarre de gancho, agarre de poder y agarre de alcance). Este conjunto de señales se dividió en un 70% para entrenamiento, un 20% para validación y un 10% para pruebas, asegurando una separación adecuada para evaluar la capacidad de generalización del modelo.

Durante el proceso de entrenamiento, el modelo alcanzó una precisión (accuracy) máxima de 0.81, mientras que en la fase de validación alcanzó una precisión máxima de 0.72. Esta diferencia sugiere que el modelo es capaz de aprender patrones en el conjunto de entrenamiento, aunque tiene dificultades para generalizar a datos nuevos. Los valores de pérdida mínima fueron de 0.6 en el entrenamiento y de 0.9 en la validación, lo cual indica que el modelo aún puede ser optimizado para mejorar su rendimiento en ciertos movimientos que parecen ser más difíciles de clasificar.

Los resultados de la clasificación en pruebas fueron variados: el modelo identificó correctamente el 100% de las señales para los movimientos de reposo, pinza de llave y agarre de alcance, demostrando que logró aprender con precisión estos movimientos. Sin embargo, mostró dificultades al clasificar las señales del agarre de gancho y el agarre de poder, con una precisión de solo el 33% y el 66.7%, respectivamente. Estos resultados sugieren que existe similitud en las características de las señales de estos movimientos, lo que genera confusión en el modelo y sugiere la necesidad de mejorar la diferenciación de estas clases. Finalmente, al implementar el sistema de control, la prótesis fue capaz de realizar cada movimiento en función de la señal clasificada, lo que valida la funcionalidad del prototipo y su capacidad de responder a las señales musculares en tiempo real. A pesar de los errores en la clasificación de algunos movimientos, el sistema cumple con los requisitos básicos de diseño y ejecución de órdenes motoras específicas.

## **Conclusiones**

En conclusión, los resultados obtenidos constituyen un avance importante en el desarrollo de una prótesis mioeléctrica funcional y adaptable. No obstante, la precisión en la clasificación de ciertos movimientos podría mejorar con técnicas avanzadas de preprocesamiento o con modelos más complejos. Una mayor diferenciación de las señales del agarre de gancho y el agarre de poder ayudaría a reducir los errores de clasificación y aumentar la confiabilidad del dispositivo. En general, estos hallazgos proporcionan una base sólida para optimizar el prototipo en futuras iteraciones y mejorar su rendimiento para su posible aplicación en usuarios reales.

## **Anexo**



Fig. 1. Modelo 3D del prototipo de la prótesis mioeléctrica.

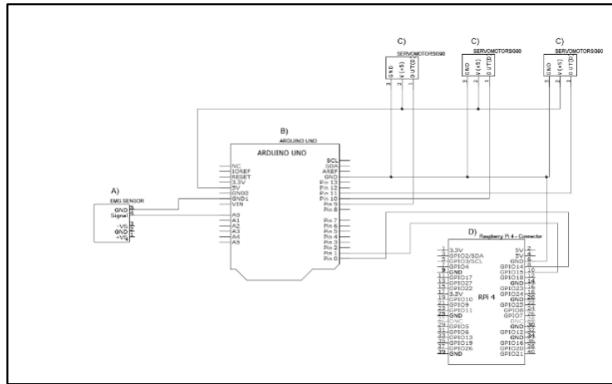


Fig. 2. Diagrama esquemático del circuito electrónico de la prótesis mioeléctrica. A) Sensor EMG, realiza la adquisición, amplificación y filtrado de la señal. B) Arduino UNO encargado de la conversión Analógico-Digital y la activación de los motores. C) Servomotores D) Raspberry Pi 4 procesador para el modelo de clasificación.

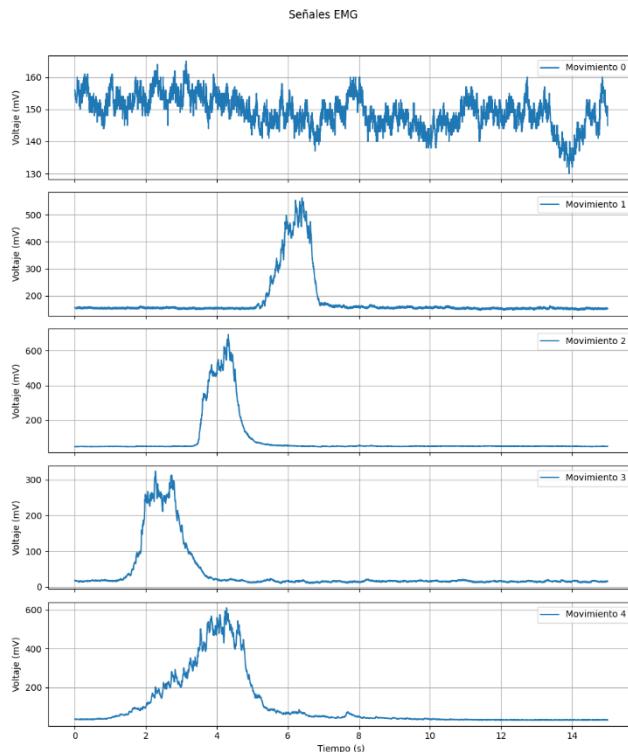


Fig. 3. Graficas de las señales electromiográficas en dominio del tiempo de las clases de movimientos. Movimiento 0 (reposo). Movimiento 1 (pinza de llave). Movimiento 2 (agarre de gancho). Movimiento 3 (agarre de poder). Movimiento 4 (agarre de alcance).

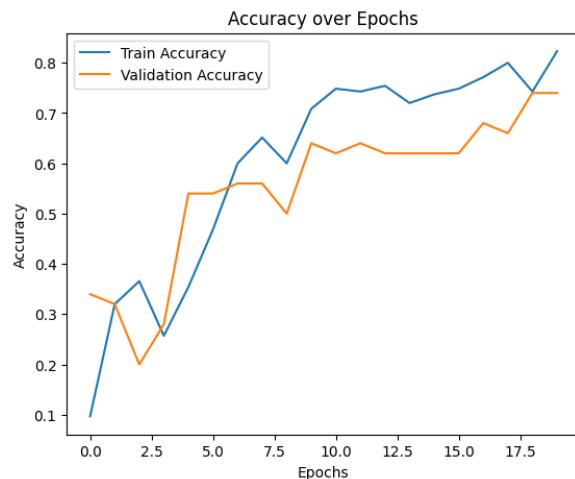


Fig. 4. Grafica de Accuracy en función de las épocas del entrenamiento y validación del modelo de clasificación.

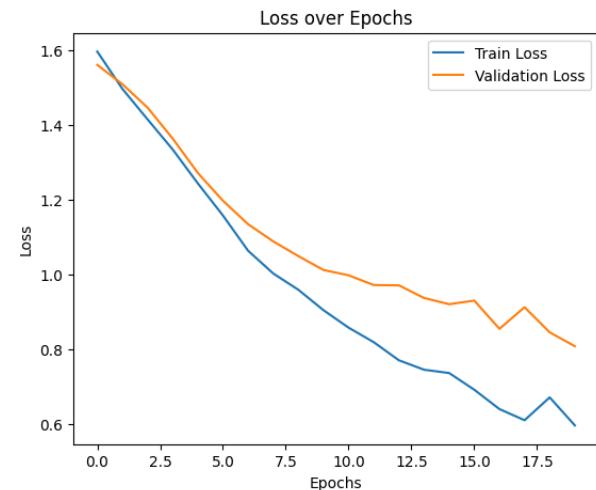


Fig. 5. Grafica de Loss en función de las épocas del entrenamiento y validación del modelo de clasificación.

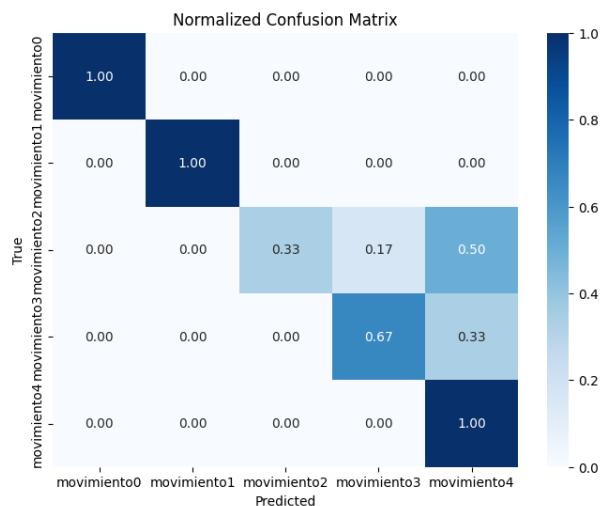


Fig. 6. Matriz de confusión normalizada del test del modelo.

## Referencias

- [1] Academia Nacional de Medicina, “Acta de la Sesión del 4 de marzo del 2015 Academia Nacional de Medicina”, en *Los amputados, un reto para el estado.*, 2015. Consultado: el 10 de febrero de 2024. [En línea]. Disponible en: <https://www.anmm.org.mx/index.php/sesiones-academicas/sesiones-academicas-2015>
- [2] T. J. Bates, J. R. Fergason, y S. N. Pierrie, “Technological Advances in Prosthesis Design and Rehabilitation Following Upper Extremity Limb Loss.”, *Curr Rev Musculoskelet Med*, vol. 13, pp. 485–493, jun. 2020.
- [3] Zacharia Isaac y Brigham and Women’s Hospital, “Rehabilitación tras la amputación de un miembro ”, Manual MSD versión para público general. Consultado: el 25 de febrero de 2024. [En línea]. Disponible en: <https://www.msdmanuals.com/es-mx/hogar/fundamentos/rehabilitaci%C3%B3n/rehabilitaci%C3%B3n-tras-la-amputaci%C3%B3n-de-un-miembro>
- [4] B. Lv, G. Chai, X. Sheng, H. DIng, y X. Zhu, “Evaluating User and Machine Learning in Short- And Long-Term Pattern Recognition-Based Myoelectric Control”, *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 29, pp. 777–785, abr. 2021, doi: 10.1109/TNSRE.2021.3073751.
- [5] D. Di Domenico *et al.*, “Hannes Prosthesis Control Based on Regression Machine Learning Algorithms”, *IEEE International Conference on Intelligent Robots and Systems*, pp. 5997–6002, dic. 2021, doi: 10.1109/IROS51168.2021.9636391.
- [6] A. Kashizadeh, K. Penan, A. Belford, A. Razmjou, y M. Asadnia, “Myoelectric Control of a Biomimetic Robotic Hand Using Deep Learning Artificial Neural Network for Gesture Classification”, *IEEE Sens J*, vol. 22, núm. 19, pp. 18914–18921, oct. 2022, doi: 10.1109/JSEN.2022.3191640.
- [7] J. M. Hahne, M. Markovic, y D. Farina, “User adaptation in Myoelectric Man-Machine Interfaces”, *Scientific Reports 2017 7:1*, vol. 7, núm. 1, pp. 1–10, jun. 2017, doi: 10.1038/s41598-017-04255-x.
- [8] Advancer Technologies, “Three-lead Differential Muscle/Electromyography Sensor for Microcontroller Applications”, feb. 2013, Consultado: el 29 de octubre de 2024. [En línea]. Disponible en: [www.AdvancerTechnologies.com](http://www.AdvancerTechnologies.com)
- [9] Raspberry Pi, “Raspberry Pi Documentation”. Consultado: el 12 de septiembre de 2024. [En línea]. Disponible en: <https://www.raspberrypi.com/documentation/>
- [10] Arduino®, “Arduino® UNO R3”, el 13 de septiembre de 2024. Consultado: el 12 de septiembre de 2024. [En línea]. Disponible en: <https://docs.arduino.cc/hardware/uno-rev3/>
- [11] G. J. Tortora y B. Derrickson, *Principios de Anatomía y Fisiología*, 13a ed. 2006.
- [12] A. Molina-Molina *et al.*, “Validation of mDurance, A Wearable Surface Electromyography System for Muscle Activity Assessment”, *Front Physiol*, vol. 11, nov. 2020, doi: 10.3389/FPHYS.2020.606287/FULL.
- [13] S. F. M. Duncan, C. E. Saracevic, y R. Kakinoki, “Biomechanics of the hand”, *Hand Clin*, vol. 29, núm. 4, pp. 483–492, nov. 2013, doi: 10.1016/j.hcl.2013.08.003.
- [14] GeeksforGeeks, “Introduction to Recurrent Neural Network ”. Consultado: el 4 de octubre de 2024. [En línea]. Disponible en: <https://www.geeksforgeeks.org/introduction-to-recurrent-neural-network/>
- [15] C. Stryker, “What is a Recurrent Neural Network (RNN)? | IBM”. Consultado: el 4 de octubre de 2024. [En línea]. Disponible en: <https://www.ibm.com/topics/recurrent-neural-networks>
- [16] “Introduction to Recurrent Neural Network - GeeksforGeeks”. Consultado: el 12 de noviembre de 2024. [En línea]. Disponible en: <https://www.geeksforgeeks.org/introduction-to-recurrent-neural-network/>
- [17] W. Bustamante Barrios, “Calculando la precisión en un modelo de Clasificación Multiclasa”. Consultado: el 4 de octubre de 2024. [En línea]. Disponible en: <https://wbarriosb.medium.com/calculando-la-precisi%C3%B3n-en-un-modelo-de-clasificaci%C3%B3n-224d96f52043>
- [18] N. Singh Chauhan, “Métricas De Evaluación De Modelos En El Aprendizaje Automático”. Consultado: el 4 de octubre de 2024. [En línea]. Disponible en: <https://www.datasource.ai/es/data-science-articles/metricas-de-evaluacion-de-modelos-en-el-aprendizaje-automatico>
- [19] R. Díaz, “Métricas de Clasificación”. Consultado: el 4 de octubre de 2024. [En línea]. Disponible en: <https://www.themachinelearners.com/metricas-de-clasificacion/>
- [20] GeeksforGeeks, “F1 Score in Machine Learning ”. Consultado: el 4 de octubre de 2024. [En línea]. Disponible en: <https://www.geeksforgeeks.org/f1-score-in-machine-learning/>